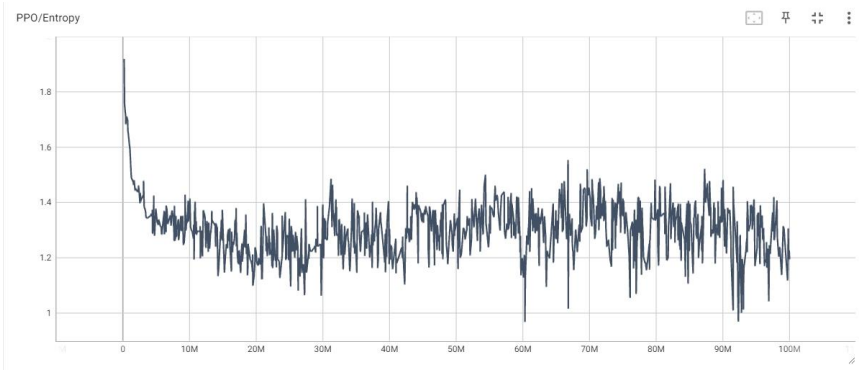
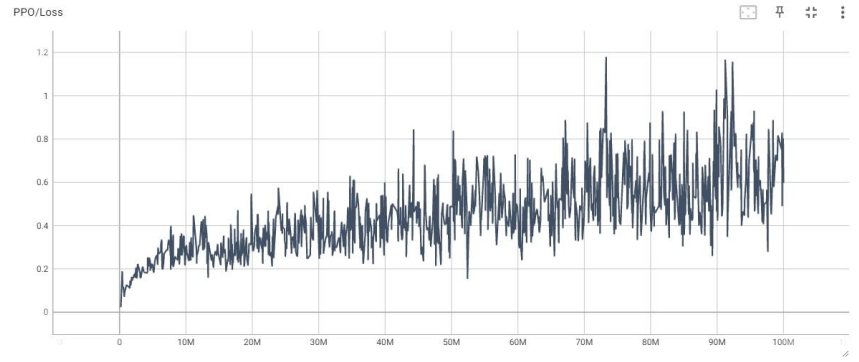
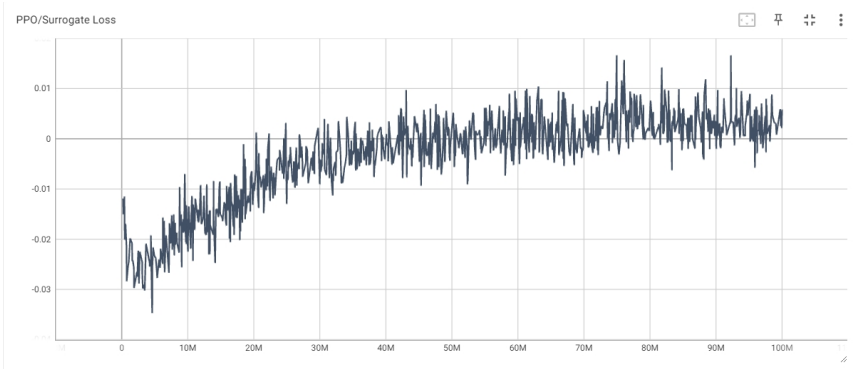
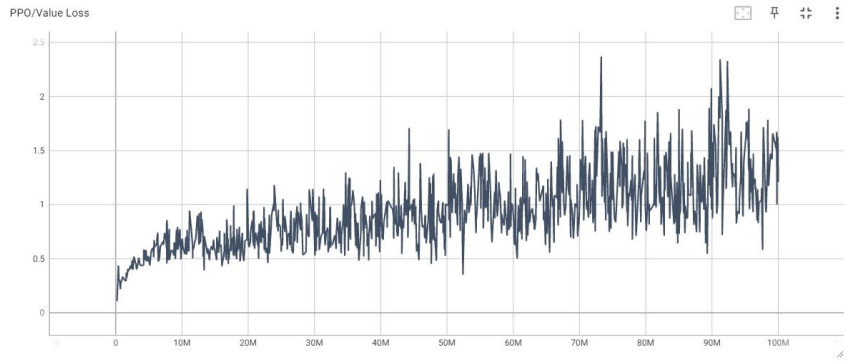
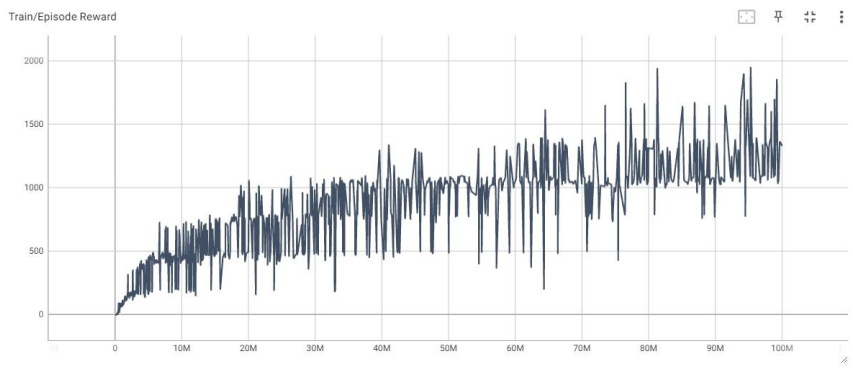
- PPO for Enduro-v5
  1. Training curve:



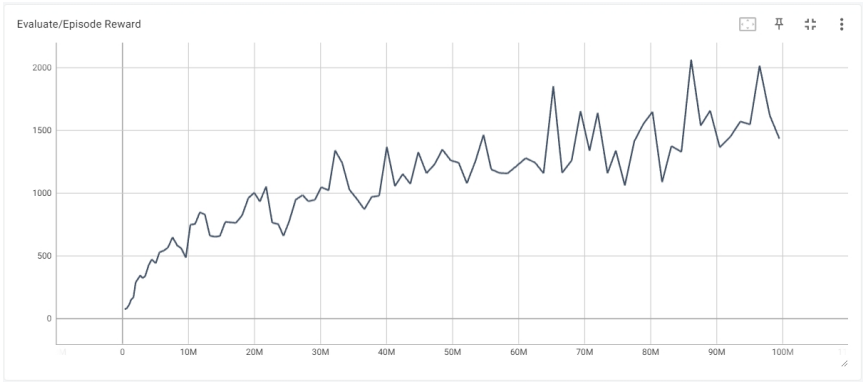








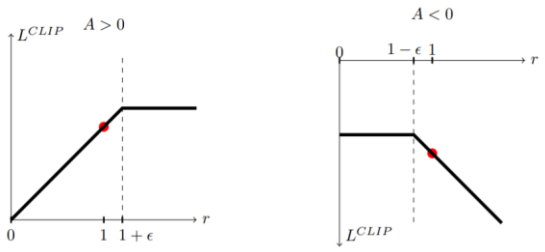
2. Testing results:




```
episode 1 reward: 1348.0
episode 2 reward: 2266.0
episode 3 reward: 2256.0
average score: 1956.6666666666667
```

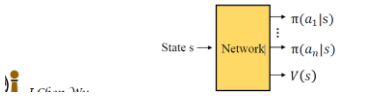
- Bonus

1. PPO is an on-policy or an off-policy algorithm? Why? (5%)
   PPO 為 on-policy algorithm。有別於 off-policy(Q-learning 、DQN)是從過去的 policy 生成的 data 來做更新，PPO 是從 current policy 所生成的 data 去學習、更新 policy。
2. Explain how PPO ensures that policy updates at each step are not too large to avoid destabilization. (5%)
   PPO 是利用 target function
   『$L^{CLIP}(\theta)=E[\min(r_t(\theta)\cdot A_t,clip(r_t(\theta),1-\epsilon,1+\epsilon)\cdot A_t)]$』來確保確每個步驟的策略更新不會過大，使得更新 policy 時可以有效控制在某個範圍內，避免掉大量更新 policy 導致的振盪或發散，policy 較能夠收斂。
   target function 的執行效果如下圖所示，當 Generalized Advantage Estimation (GAE) A_t 大於 0，r_t(新、舊 policy 概率的比率)超過 $1+\epsilon$ 時，$L^{CLIP}(\theta)$會被 clip；當 A_t 小於 0，r_t 小於 $1-\epsilon$ 時，$L^{CLIP}(\theta)$會被 clip。



3. Why is GAE-lambda used to estimate advantages in PPO instead of just one-step advantages? How does it contribute to improving the policy learning process? (5%)

$$\hat{A}_t = \delta_t + (\gamma\lambda)\delta_{t+1} + \cdots + (\gamma\lambda)^{T-t+1}\delta_{T-1}$$
where $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$



$\widehat{A_t}$ is generalized advantage estimation (GAE)

(1) 因為 GAE-lambda 結合多個時間點的信息，降低在評估 advantage 時的 variance，並處理了 reward 延遲問題，以及 bias 和 variance 之間平衡的問題。以上的特點使 PPO 在應付複雜的 environment 時，能夠更加的穩定、有效。

(2) GAE-lambda 提升 policy learning process 有以下 4 點:

1. Temporal Abstraction :

Lambda 為 temporal decay factor，它決定了 future time steps 對評估 advantage 的貢獻程度。Lambda 使得演算法能夠得到現在和未來每一 step 的 reward 和 value。

2. Reducing Variance in Advantage Estimates :

我們可以透過 lambda 對 short-term 和 long-term 的 advantages 同時做觀察，已將低 variance，避免過於樂觀或悲觀的估算 Advantage。

3. Handling Delayed Rewards :

當我們在 S_t 做出 action 時，environment 並不會立即產生 reward，導致我們在立刻決定 S_{t+1} 的 action，所以透過 GAE-lambda 考慮隨著時間所累積的 reward 對 action 的影響。

4. Balancing Bias and Variance in advantage estimation:

GAE 在估算 advantage 時，於 bias(過度偏頗)和 variance(發散)中取得平衡。我們可以通過調整 lambda 的值，來決定只考慮 short-term 的 advantage(lambda = 0)，還是 short-term、long-term 的 advantage(lambda 0~1)一起當作考量依據。這麼做使得 programmer 可以依據 environment 的特性對 RL model 做 fine-tune(微調)。

4. Please explain what the lambda parameter represents in GAE-lambda, and

how adjusting the lambda parameter affects the training process and performance of PPO? (5%)

$$\hat{A}_t = \delta_t + (\gamma\lambda)\delta_{t+1} + \cdots + (\gamma\lambda)^{T-t+1}\delta_{T-1}$$
where $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$

Lambda 的值介於 0 到 1 之間，如上圖所示，lambda(λ)作為 A_t 式子中每一項的 weight，用來決定要參考 short-term 還是 long-term 的 advantage 多一點，來估算整體的 advantage A_t。

- 以下探討接近 0 和 1 的 lambda 對整體 advantage 的影響。
  1. Lambda = 0
     只參考 short-term 的 advantage。PPO 容易變得極度偏頗。
  2. Lambda 接近 0
     著重參考 short-term 的 advantage，當下的 reward 對整體 model 也占有極大的影響。雖然 variance 降低，但 bias 增加，model 會太過偏頗。
  3. Lambda = 1
     參考了所有時間點的 advantage，整體的 advantage 容易發散，不易收斂。
  4. Lambda 接近 1
     可以保留並參考多個時間點的信息，雖降低了 bias 但 variance 升高，所以須訓練多次的 episode 之後才能收斂。